

1. prompt

- 已了解。

- 已实现内容：

- 1/9

7. 基于 TF-IDF 矩阵转置后做 `TruncatedSVD(n_components=2)` (LSA)
8. 用二维散点图展示词汇空间，并标注词项
9. 包含异常处理：
10. NLTK `punkt` 资源自动检查/下载
11. 输入文本过短或句子不足时给出提示
12. 整个模块运行时捕获异常并显示报错详情
13. 第 2/3/4 标签页已预留占位，便于你后续分模块继续实现。

运行方式：在当前目录执行：`streamlit run app.py`

- 请在模块 1 中增加功能：将同现频率高的词语（如主语和相关动词）映射到相近的坐标。

GPT-5.3-Codex-Medium：

已完成“模块 1 观察任务”的功能增强，你现在可以在页面里直接验证“高同现词是否映射到更近坐标”。

- 模块 2：Word2Vec 训练与对比 (CBOW vs Skip-Gram)——在第二个标签页中，实现 Word2Vec 的实时训练和测试。
 1. 使用与模块1相同的语料（或其他语料），调用 `gensim.models.Word2Vec` 进行训练。
 2. 在界面上提供单选按钮，允许用户切换训练架构：CBOW (`sg=0`) 或 Skip-Gram (`sg=1`)。
 3. 提供滑动条 (Slider) 调整 window（上下文窗口，2-10）等参数。
 4. 提供一个单词输入框，计算并输出在当前训练模型下，与该词余弦相似度 (Cosine Similarity) 最高的 5 个词汇。

GPT-5.3-Codex-Medium：

已实现模块 2（第二标签页）：

1. 使用与模块 1 同源文本进行 Word2Vec 实时训练 (`gensim.models.Word2Vec`)。
2. 提供 CBOW / Skip-Gram 单选切换（对应 `sg=0` / `sg=1`）。
3. 提供参数滑条：
4. window (2-10)
5. vector_size
6. epochs
7. min_count
8. 提供查询词输入框，输出当前模型下 Top-5 余弦相似词。

运行方式：在当前目录执行：`streamlit run app.py`

- 模块 3：预训练模型与词类比 (GloVe) 在第三个标签页中，测试预训练的 GloVe 模型与词类比任务。
 1. 在后台使用 `gensim.downloader` 加载预训练模型 `glove-twitter-25`（为保证速度可选用轻量级模型）。

2. 构建词类比 (Word Analogy) 计算器: 提供 A, B, C 三个输入框。
3. 在后台计算向量公式: $\text{Result} = \text{Vector}(A) - \text{Vector}(B) + \text{Vector}(C)$ 。
4. 检索并输出距离 Result 向量最接近的单词。
5. 补充一个基础功能: 输入任意两个单词, 计算它们的词义相似度分数。

GPT-5.3-Codex-Medium:

模块 3 已完成并接入第三标签页, 且已在 py310 环境下通过语法与导入校验。

已实现功能:

1. 预训练模型加载

- 使用 `gensim.downloader` 加载 `glove-twitter-25`
- 使用缓存避免重复下载与重复初始化

2. 词类比计算器 (A, B, C)

- 三个输入框接收 A/B/C
- 后台按公式计算 $\text{Result} = \text{Vector}(A) - \text{Vector}(B) + \text{Vector}(C)$
- 检索并输出与 Result 最接近的词, 同时展示前 5 个候选词

3. 两词相似度

- 输入任意两个词
- 计算并展示词义相似度分数 (余弦相似度)

4. 异常处理

- 模型未加载提示
- 词不在词表提示
- 输入不完整提示
- 运行异常统一捕获并展示

运行方式: 在当前目录执行: `streamlit run app.py`

- 模块 4: 子词特征与句向量 (FastText & Sent2Vec)——在第四个标签页中, 实现 FastText 与句子级表示 (Sent2Vec)。
 1. 使用之前的语料实时训练一个 `gensim.models.FastText` 模型。
 2. OOV 测试: 提供一个输入框, 故意输入一个带有拼写错误的词 (如 'computer'). 分别尝试用之前的 Word2Vec 和现在的 FastText 提取向量。用 try-except 捕获 Word2Vec 的 `KeyError` 并在界面提示“未登录词”, 同时展示 FastText 成功计算出的最相似词。
 3. Sent2Vec (简单实现): 提供两个较长的句子输入框。将句子分词后, 提取所有词的向量 (可使用 FastText 向量) 并求均值 (Average Pooling), 得到两个句子的全局向量 (模拟 Sent2Vec 基本思想)。
 4. 计算并输出这两个句向量的余弦相似度。

GPT-5.3-Codex-Medium:

已完成模块 4，并已在 py310 环境校验通过。

对应你的 4 条要求，已实现如下：

1. 实时训练 FastText
- 在第四标签页加入语料输入与参数滑条（`window` 2-10、`vector_size`、`epochs`、`min_count`），点击按钮后即时训练 `gensim.models.FastText`。
2. OOV 测试（Word2Vec vs FastText）
- 同一语料下同时训练一个 Word2Vec（用于对照）和 FastText。
 - 输入如 `computeer` 时，Word2Vec 取向量用 `try-except KeyError` 捕获，并显示“Word2Vec：未登录词”。
 - FastText 对同词可构造子词向量，并展示最相似的 Top 5 词。
3. Sent2Vec 简化实现
- 提供两个长句输入框。
 - 分词后取 FastText 词向量并做平均池化（Average Pooling）得到两个句向量。
4. 句向量余弦相似度
- 计算并输出两个句向量的 cosine similarity 分数。

运行方式： 在当前目录执行：`streamlit run app.py`

2. 截图



分句完成: 共 11 句。

查看句子级文档集合

1. Natural language processing is a field of artificial intelligence that studies how computers and humans communicate through language.
2. Researchers build representations of words, sentences, and documents so that machines can analyze meaning, sentiment, and context.
3. Traditional methods often begin with counting word frequencies and weighting terms by inverse document frequency.
4. These approaches are interpretable and efficient for many applications.
5. Modern methods use distributed representations where words are mapped into dense vectors learned from data.
6. In these vector spaces, semantically related words tend to appear close to one another.
7. For example, words about medicine may share similar contexts, while words about finance form another cluster.
8. Dimensionality reduction techniques can project high-dimensional vectors into two dimensions for visualization.
9. Such visualizations help learners understand latent semantic structure and compare model behavior.
10. In teaching and experimentation, interactive tools are useful because students can modify text and immediately observe numerical and geometric changes.
11. By combining statistical features with low-rank decomposition, we can demonstrate both classic information retrieval ideas and the intuition behind semantic spaces.

TF-IDF 矩阵 (句子 × 词汇)


	analyze	appear	applications	approaches	artificial	begin	behavior	build	changes	classic	close	cluster	combining	communicate	compare	computers	context	contexts	co
0	0	0	0	0	0.2774	0	0	0	0	0	0	0	0	0.2774	0	0.2774	0	0	
1	0.3134	0	0	0	0	0	0	0.3134	0	0	0	0	0	0	0	0	0.3134	0	
2	0	0	0	0	0	0.3053	0	0	0	0	0	0	0	0	0	0	0	0	
3	0	0	0.5	0.5	0	0	0	0	0	0	0	0	0	0	0	0	0	0	
4	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	
5	0	0.3731	0	0	0	0	0	0	0	0	0.3731	0	0	0	0	0	0	0	

Top 5 关键词 (按全局 TF-IDF 权重)

	keyword	weight
0	words	1.1066
1	vectors	0.5645
2	language	0.5547
3	spaces	0.5519
4	representations	0.5431



LSA 二维词汇空间可视化




已显示标签 7 个（自动跳过重叠位置）。

观察任务：共现矩阵分解的 LSA

下方使用句子级共现矩阵 (X^TX) 进行分解，用于检验高同现词在二维空间是否更接近。

查看共现矩阵（词汇 × 词汇）

	analyze	appear	applications	approaches	artificial	begin	behavior	build	changes	classic	close	cluster	combining	communicate	compare	computers	context
analyze	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	1
appear	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0
applications	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0
approaches	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0
artificial	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	1	0
begin	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
behavior	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0
build	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1
changes	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
classic	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
close	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
cluster	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
combining	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
communicate	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
compare	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
computers	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
context	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0



共现图已显示标签 7 个（自动跳过重叠位置）。

高同现词对与 LSA 距离

	word_1	word_2	cooccurrence	lsa_distance
4,715	representations	words	2	0.9759
3,161	geometric	observe	1	0
4,671	related	tend	1	0
1,457	computers	natural	1	0
1,994	dense	distributed	1	0
4,224	medicine	share	1	0
2,680	experimentation	interactive	1	0
4,538	processing	studies	1	0
735	build	meaning	1	0
2,163	dimensionality	high	1	0

自定义词对检查

词 1词 2

analyzeappear

同现次数: 0

LSA 二维距离: 1.4009

该词对无同现关系，通常其空间距离会更大。

模块 1: TF-IDF 与 LSA 模块 2: Word2Vec/GloVe/FastText 模块 3: 预训练 GloVe 与词类比 模块 4: FastText 与 Sent2Vec

模块 2：Word2Vec 训练与对比 (CBOW vs Skip-Gram)

基于输入语料实时训练 Word2Vec，并输出目标词的 Top-5 余弦相似词。

请输入英文文本（与模块 1 可保持一致）

Natural language processing is a field of artificial intelligence that studies how computers and humans communicate through language. Researchers build representations of words, sentences, and documents so that machines can analyze meaning, sentiment, and context. Traditional methods often begin with counting word frequencies and weighting terms by inverse document frequency. These approaches are interpretable and efficient for many applications. Modern methods use distributed representations where words are mapped into dense vectors learned from data. In these vector spaces, semantically related words tend to appear close to one another. For example, words about medicine may share similar contexts, while words about finance form another cluster. Dimensionality reduction techniques can project high-dimensional vectors into

选择训练架构

CBOW

Skip-Gram

window (上下文窗口)

vector_size (向量维度)

epochs (训练轮数)

5

80

80

2

10

20

200

10

200

min_count (最小词频)

1

5

1

输入待查询单词

language

训练并查询相似词

训练完成: CBOW, 词表大小 134, 句子数 11。

查看词表样例

and, words, can, for, are, semantic, about, another, to, spaces, in, vectors, into, these, by, with, methods, representations, that, of, language, behind, intuition, the, ideas, retrieval, information, classic, both, demonstrate, we, decomposition, rank, low, features, statistical, combining, changes, geometric, numerical, observe, immediately, text, modify, students, because, useful, tools, interactive, experimentation, teaching, behavior, model, compare, structure, latent, understand, learners, help, visualizations, such, visualization, dimensions, two, dimensional, high, project, techniques, reduction, dimensionality, cluster, form, finance, while, contexts, similar, share, may, medicine, example

与 'language' 最相似的 5 个词

	word	cosine_similarity
0	and	0.5906
1	close	0.5591
2	mapped	0.5174
3	intelligence	0.5167
4	data	0.5145

选择训练架构

CBOW

Skip-Gram

window (上下文窗口)

vector_size (向量维度)

epochs (训练轮数)

5

80

80

2

10

20

200

10

200

min_count (最小词频)

1

5

1

输入待查询单词

language

训练并查询相似词

训练完成: Skip-Gram, 词表大小 134, 句子数 11。

查看词表样例

and, words, can, for, are, semantic, about, another, to, spaces, in, vectors, into, these, by, with, methods, representations, that, of, language, behind, intuition, the, ideas, retrieval, information, classic, both, demonstrate, we, decomposition, rank, low, features, statistical, combining, changes, geometric, numerical, observe, immediately, text, modify, students, because, useful, tools, interactive, experimentation, teaching, behavior, model, compare, structure, latent, understand, learners, help, visualizations, such, visualization, dimensions, two, dimensional, high, project, techniques, reduction, dimensionality, cluster, form, finance, while, contexts, similar, share, may, medicine, example

与 'language' 最相似的 5 个词

	word	cosine_similarity
0	and	0.9944
1	intelligence	0.9943
2	processing	0.9934
3	data	0.9934
4	can	0.9934

使用预训练 glove-twitter-25, 完成词类比 A - B + C 与词义相似度测试。

加载 GloVe 模型 (glove-twitter-25)

模型加载完成, 词表大小: 1193514

输入 A

king

1

输入 B

man

输入 C

woman

计算类比结果

单词 1

happy

单词 2


joy

计算两词相似度

实时训练 FastText，完成 OOV 对比测试，并用平均池化构建句向量相似度。

请输入英文文本（建议与前面模块一致）

Natural language processing is a field of artificial intelligence that studies how computers and humans communicate through language. Researchers build representations of words, sentences, and documents so that machines can analyze meaning, sentiment, and context. Traditional methods often begin with counting word frequencies and weighting terms by inverse document frequency. These approaches are interpretable and efficient for many applications. Modern methods use distributed representations where words are mapped into dense vectors learned from data. In these vector spaces, semantically related words tend to appear close to one another. For example, words about medicine may share similar contexts, while words about finance form another cluster. Dimensionality reduction techniques can project high-dimensional vectors into



训练 FastText 并执行模块 4

训练完成: Word2Vec 词表 134, FastText 词表 134。

输入一个可能拼写错误的词

computer

执行 OOV 对比

句子 1

Natural language processing helps computers understand human language in practical applications.

句子 2

Machines learn semantic patterns from text so they can analyze meaning more effectively.

计算句向量相似度

本次 Vibe 实验把课堂里的几类语义表示方法真正跑通了：从 TF-IDF/LSA 的统计表示，到 Word2Vec 的上下文学习，再到 GloVe 的线性类比能力，以及 FastText 对未登录词的鲁棒性和句向量均值法的句级语义比较。通过同一平台下的可视化与对比，我更直观地理解了不同模型擅长什么、局限在哪。整体来看，传统方法可解释性强，神经向量方法语义表达更丰富，二者结合能更好地支持实际文本分析任务。

- 从结果看，基于共现矩阵分解的 LSA 能较好捕捉词语的上下文关联。高同现词对在二维空间中通常更接近，像主语与其常搭配动词会聚成小簇；而共现较少的词距离普遍更远。说明 LSA 虽是线性降维方法，仍能在一定程度上还原文本中的潜在语义结构。

- 在相同语料与参数下切换后，CBOW 与 Skip-Gram 的 Top 5 相似词通常会出现明显差异。CBOW 更偏向学习高频词的平均上下文，结果往往更稳定、语义更平滑；而 Skip-Gram 对低频词和细粒度搭配更敏感，返回词可能更分散但更有区分度。由此可见，两种架构对“相似性”的刻画重点不同：前者强调整体语境，后者更强调局部共现关系。

- 在测试中，`king - man + woman` 的结果通常会回到 `queen` 或非常接近的词，说明 GloVe 的确学到了一部分性别替换关系。国家与首都类比里，`Paris - France + China` 往往能给出 `Beijing` 或相关候选，但稳定性不如经典性别例子。继续尝试如 `Tokyo - Japan + France`、`Berlin - Germany + Italy`、`Madrid - Spain + Portugal`、`Rome - Italy + Japan` 后可以发现：常见实体关系更容易被捕捉，低频或歧义较大的词对结果波动更明显。

- 在测试中，拼写错误词如 `computeer` 用 Word2Vec 往往直接报未登录词，而 FastText 仍能给出合理近邻，说明其基于字符 n-gram 的表示对 OOV 更稳健。句向量均值法方面，语义接近的两句通常得到更高余弦相似度，主题差异较大的句子分数明显下降。整体来看，FastText 在噪声文本处理上更实用，均值句向量虽简单，但能较直观地反映句子层面的全局语义接近程度。