

1. prompt

- 我将进行《自然语言处理》这门课的 A7 作业：Week 8 随堂 Vibe 实验：信息抽取与知识图谱构建系统。本次实验的背景与目的是：在本周的理论课中，我学习了信息抽取（Information Extraction, IE）的核心任务。从非结构化文本中抽取出结构化信息，主要包括命名实体识别（NER，如人物、组织、地点等）、关系抽取（Relation Extraction，如“创始人”、“位于”）以及事件抽取。本次实验，请利用 AI 辅助编程工具（Vibe Coding 模式），开发一个集成 NER、关系抽取与知识图谱可视化的交互式 Web 系统。你将通过实际文本的处理，直观理解信息抽取的流程、不同类型实体的识别（平铺 vs 嵌套）以及结果的可视化表达。。本次实验分为三个模块，我将分模块发送（请了解这个作业的总体要求，不需要回复我任何信息）。总体要求为：使用 Python Streamlit 结合前端组件，结合可视化图表库（如 vis-network 或 echarts），构建一个包含完整抽取链路与可视化功能的应用。

已了解。

- 模块 1: 命名实体识别与 BIO 标注 (NER & BIO Tagging)
 1. 对应内容: 命名实体识别定义与挑战、平铺与嵌套实体、序列标注与 BIO 标注体系
 2. 具体要求: 实现 Web 应用的第一个核心功能: 文本输入与实体高亮识别。提供一个多行文本域, 允许用户粘贴一段英文或中文语料。编写一个抽取函数 (初期可要求 AI 使用 Mock 数据, 进阶时可调用 spaCy 库或大模型 API)。在页面上展示识别出的实体, 使用不同的背景颜色高亮不同类别的实体 (如 Person、Organization、Location)。关键功能: 提供一个 Checkbox (复选框) 以切换是否开启“查看底层标注”模式。开启后, 将文本的高亮展示直接切换为对应的 BIO 序列 (如 B-PER, I-PER, O) 纯文本展示。

静态检查通过，模块 1 已可运行。我接下来给你一版可直接提交到作业记录里的结果说明，并附上运行方式。模块 1 已按你这次要求完成，采用 Python Streamlit 实现了可运行版本。

- app.py
- requirements.txt

实现内容对应你的要求:

1. 多行文本输入：支持中英文语料粘贴输入。

2. 实体识别与高亮：内置 Mock/规则混合抽取函数，识别 Person/Organization/Location，并按类别高亮显示。
3. BIO 切换：提供复选框“查看底层标注 (BIO)”，开启后展示 token + B/I/O 序列纯文本。
4. 结果面板：同时展示实体表格（文本、类别、起止位置）。
5. 平铺与嵌套说明：当前实现为平铺实体去重策略，并在界面中注明嵌套实体的扩展方向（多层或 span 方案）。

我已做静态检查，当前代码无错误。

运行方式：

1. 安装依赖：pip install -r requirements.txt
2. 启动应用：streamlit run app.py

如果你继续发送模块 2，我会在这个 Streamlit 版本上直接无缝接入关系抽取与三元组表格。

已进行更改。

- 模块 2：实体关系抽取 (Relation Extraction)
 1. 对应内容：关系抽取 (Relation Extraction, RE)
 2. 具体要求：在实体识别的基础上，增加关系抽取模块。修改前面的抽取函数，使其不仅返回实体列表，还能返回实体对之间的语义关系（例如 {source: 'Steve Jobs', target: 'Apple', relation: 'FOUNDER_OF'}）。在页面新增一个数据面板，使用表格 (Table) 的形式清晰列出所有抽取到的主体 (Subject)、客体 (Object) 以及它们之间的关系词 (Predicate)。

GPT-5.3-Codex-Medium：

模块 2 已经在现有 Streamlit 应用里完成并通过检查。

已更新：

- app.py

这次新增内容：

1. 抽取流程升级
 - 新增统一入口 `extract_info(text)`，同时返回：
 - `entities`
 - `relations`（三元组结构：`source / relation / target`）
2. 关系抽取模块
 - 新增 `extract_relations(text, entities)`，当前规则支持：
 - `FOUNDER_OF`：匹配“创立/创办/创建/founded/founder”
 - `LOCATED_IN`：匹配“位于/总部/located in/headquartered in/based in”
 - 包含去重逻辑，避免重复关系行。

3. 页面新增关系结果面板

- 在实体列表下新增“关系抽取结果 (Subject - Predicate - Object)”表格。
- 无结果时给出提示信息。

4. 保留模块 1 功能

- 文本输入、多类别实体高亮、BIO 切换都保持可用。

校验结果：

- app.py 无错误（静态检查通过）。

你现在可以直接运行：

- `streamlit run app.py`

并用示例测试：

- Steve Jobs founded Apple. Apple is based in California.
- 马云创立了阿里巴巴，总部位于杭州。

如果你继续发模块 3，我会在此基础上接入知识图谱可视化 (nodes/edges + 交互)。

已进行更改。

- 模块 3：知识图谱交互可视化 (Knowledge Graph Visualization)
 1. 对应内容：信息抽取在构建知识图谱等高级应用中的作用
 2. 具体要求：在页面引入 vis-network.js (或 Echarts) 网络图可视化库。编写数据转换代码，将模块 1 和 2 中提取到的 entities 转换为图谱中的 nodes（节点），将 relations 转换为图谱中的 edges（边）。配置节点样式，使得不同类型的实体拥有不同的颜色和大小；配置边的样式，使其带有箭头并显示关系标签。将知识图谱渲染在页面的主要展示区，并确保支持鼠标拖拽节点和滚轮缩放。

GPT-5.3-Codex-Medium：

2. 实验总结

本次实验让我把课堂中的信息抽取流程真正“跑通”了一遍：先做命名实体识别，用 BIO 标注明确实体边界；再在实体基础上抽取主体、谓词、客体关系；最后将结果映射为知识图谱中的节点与边，实现可视化呈现。通过中英文样例测试，我直观看到从非结构化文本到结构化数据的转化过程，也发现了规则法在指代消解、复杂句和嵌套实体上的局限。整体来看，这次实验不仅加深了我对 NER、RE 与图谱构建衔接关系的理解，也提升了我将 NLP 理论落地为可交互系统的实践能力。

2.1 模块 1 观察任务：1. 输入包含人名和机构名的句子（如“Steve Jobs founded Apple”）。观察并对比直观的 UI 高亮与底层的 BIO 标注序列。体会课件中 B（Begin）、I（Inside）、O（Outside）是如何帮助模型确定实体边界的。2. 思考：如果在语料中出现嵌套实体（如“University of California, Los Angeles”，其中“Los Angeles”本身也是地名），简单的单层 BIO 标注会遇到什么挑战？

- 1. 在输入“Steve Jobs founded Apple”后，界面会把“Steve Jobs”标成 Person，把“Apple”标成 Organization。切到 BIO 视图可见：Steve 为 B-PER，Jobs 为 I-PER，founded 为 O，Apple 为 B-ORG。这种“起点+延续+非实体”的标注方式，能把实体边界切得很清楚，也便于模型学习不同类型实体的起始位置与跨度。
- 2. 单层 BIO 在嵌套实体里容易“顾此失彼”。如“University of California, Los Angeles”既可整体作机构，也包含地点“Los Angeles”。同一 token 在同一层只能有一个标签，导致要么保留外层机构、丢失内层地点，要么反过来破坏整体边界。因此单层 BIO 对重叠结构表达能力有限，常需多层标注或 span 方案补充。

2.2 模块 2 观察任务：1. 输入一些结构复杂的句子（包含从句或指代词，如 "He"）。观察系统（或大模型 API）是否能够准确判断出关系。2. 理解关系抽取本质上是在图结构中为两个实体节点之间预测是否存在特定语义类型的边。

- 1. 在输入含从句和指代的句子后，我发现关系抽取的稳定性明显下降。例如“Steve Jobs founded Apple, and he led it for years.”里，“Steve Jobs-Apple”的创始关系通常能识别，但“he”“it”的指代若不先做共指消解，系统很难把后续动作准确挂回原实体。句子一旦跨分句、跨代词，关系判断就不只看关键词，还依赖上下文链条。
- 2. 关系抽取可以理解为“给知识图谱加边”的过程：NER先确定节点是谁，RE再判断节点之间是否存在某类语义连接。以“马云—阿里巴巴”为例，若预测为“FOUNDER_OF”，本质就是在人物节点与机构节点间新增一条带类型的有向边。边的类型越准，图谱检索和推理越可靠；类型错了，后续问答和分析都会被连带影响。

2.3 模块 3 观察任务：输入一段包含多个人物和机构的复杂商业新闻，点击抽取后，观察生成的知识图谱是如何将“线性文本”瞬间转化为“网状结构数据”的。

- 输入一段包含多位企业家、公司及合作事件的新闻后，系统先识别出“人物”“机构”等实体，再把“创立、收购、合作、任职”等关系连成带方向的边。原本按时间顺序展开的句子，被重组为“节点-关系-节点”的网络：谁与谁直接关联、谁处于关系中心、哪些机构被多人共同连接，都能在图上立刻看清，信息结构比纯文本更直观。